Un motor de OCR para un archivo histórico militar: dos GPU, cinco lectores y ninguna palabra inventada

Javier Chaos · Museo de Historia Militar (Málaga) · noviembre de 2026
Informe técnico preliminar. Licencia: CC BY 4.0
linkedin.com/in/javierchaos · github.com/jachaos

Resumen. Este informe explica cómo he montado el motor de OCR que va a leer el archivo de uniformidad del Museo de Historia Militar: más de 300.000 páginas de cartillas, reglamentos, diarios oficiales, escalafones, láminas y documentos manuscritos de los siglos XVIII a XX. El requisito que guía todo el diseño es que el sistema no se invente nada. Lo que no se lee con seguridad se devuelve como `[ilegible]`, con las lecturas candidatas, y solo deja de serlo cuando dos lectores independientes coinciden. El motor corre en hardware propio: un servidor con una RTX 5090 hace la lectura (PaddleOCR, glm-ocr y qwen3.8) y un segundo equipo con una RTX 5070 Ti hace una revisión cruzada con un modelo de otra familia (gemma4). Gemini 3.8 Flash interviene solo como último recurso, para los huecos que nadie ha resuelto y para los documentos manuscritos. En una noche de producción procesó 4.093 páginas a unos 6,8 s por página. En una prueba de ocho documentos enviados a la vez, encadenar las dos etapas redujo el tiempo de 451 a 318 s, y Gemini elevó la proporción de `[ilegible]` resueltos del 46-49 % al 87-89 %. También cuento lo que no funcionó y por qué cambié cada decisión. **Es una versión preliminar:** el sistema está montado y probado con unas 4.000 páginas reales, pero aún falta lo importante, procesar las más de 300.000 páginas del archivo y medir a esa escala la precisión real, la velocidad, el coste de Gemini y el volumen de revisión humana.

Contenido

1. El reto y las restricciones 3
2. Visión general del sistema 3
    2.1 Hardware y software 5
    2.2 Un único punto de entrada 5
3. El proceso, fase a fase 5
    3.1 Lectura y análisis de página 5
    3.2 Clasificación del documento 5
    3.3 La regla del [ilegible] 6
    3.4 Tablas: doble lectura y sumas 8
    3.5 Revisión cruzada en el segundo equipo 9
    3.6 Gemini como último recurso 9
    3.7 Manuscritos 10
    3.8 Diccionario y revisión humana 11
    3.9 Signos y convenciones de época 11
4. Operación: cola, etapas y registros 12
5. Cómo lo he probado 12
6. Resultados 13
7. Qué funcionó y qué no 17
8. Limitaciones y problemas abiertos 18
9. Siguiente paso: las 300.000 páginas 19

1. El reto y las restricciones

El Museo de Historia Militar de Málaga es una colección privada dedicada a la uniformidad militar española. Ahora mismo está cerrado al público mientras busco un nuevo local. Este proyecto de digitalización sirve para poder exponer en línea, mientras tanto, el archivo y el catálogo: que la documentación se pueda consultar y buscar aunque las salas estén cerradas.

El archivo de uniformidad reúne más de 300.000 páginas digitalizadas de procedencias muy distintas. Hay normativa impresa (reales órdenes, circulares, reglamentos y cartillas de uniformidad), publicaciones oficiales seriadas (Diario Oficial, Gaceta, Colección Legislativa, escalafones), libros y revistas, láminas y fotografías, y documentos de archivo manuscritos. La tipografía va del siglo XVIII al XX, el papel está a menudo amarillento o con tinta desvaída, y abundan las tablas con importes, efectivos o prendas.

El catálogo de uniformidad necesita de cada documento cuatro cosas: el texto con las coordenadas de cada línea, las regiones de la página (texto, títulos, tablas, figuras, sellos), las tablas en una estructura utilizable y el tipo de documento. Cinco restricciones han dado forma a cada decisión.

- **No inventar.** Un texto plausible pero falso es peor que un hueco: entra en el catálogo y nadie vuelve a mirarlo. Un modelo de visión que «rellena» una palabra que no ve, o un año que no está, contamina el catálogo sin dejar rastro. Por eso todo lo que no se lee con seguridad se devuelve marcado como `[ilegible]`.
- **Hardware propio.** La lectura se hace en local, con un servidor y un equipo de trabajo que ya tenía. El servidor no tiene ningún servicio que se conecte al exterior; la única excepción, añadida después y de forma explícita, es Gemini como último recurso (sección 3.6).
- **Un único punto de entrada.** El catálogo solo habla con un punto de entrada HTTPS protegido. El reparto interno del trabajo entre equipos es invisible para él.
- **Volumen.** A la escala del archivo, un segundo por página son 3,5 días de proceso continuo. La velocidad importa tanto como la calidad.
- **Fidelidad al original.** No se moderniza la ortografía ni se desarrollan las abreviaturas: «Reales ordenes», «paño», «dho.», «112'50» e «Idem» se transcriben como están.

2. Visión general del sistema

El sistema es un orquestador (FastAPI) que reparte cada documento entre cinco lectores con funciones distintas, en dos etapas encadenadas (Figura 1). La primera etapa corre entera en el servidor: análisis de página con PaddleOCR, clasificación con qwen3.8, lectura de tablas y figuras, contraste de las líneas dudosas con glm-ocr y una primera resolución de los `[ilegible]` con qwen3.8. La segunda etapa empieza en cuanto termina la primera, y mientras tanto el servidor ya está con el documento siguiente. En ella, gemma4, en el segundo equipo, revisa por su cuenta lo dudoso; después Gemini resuelve lo que nadie ha resuelto, y lo que queda pasa al diccionario para revisión humana.

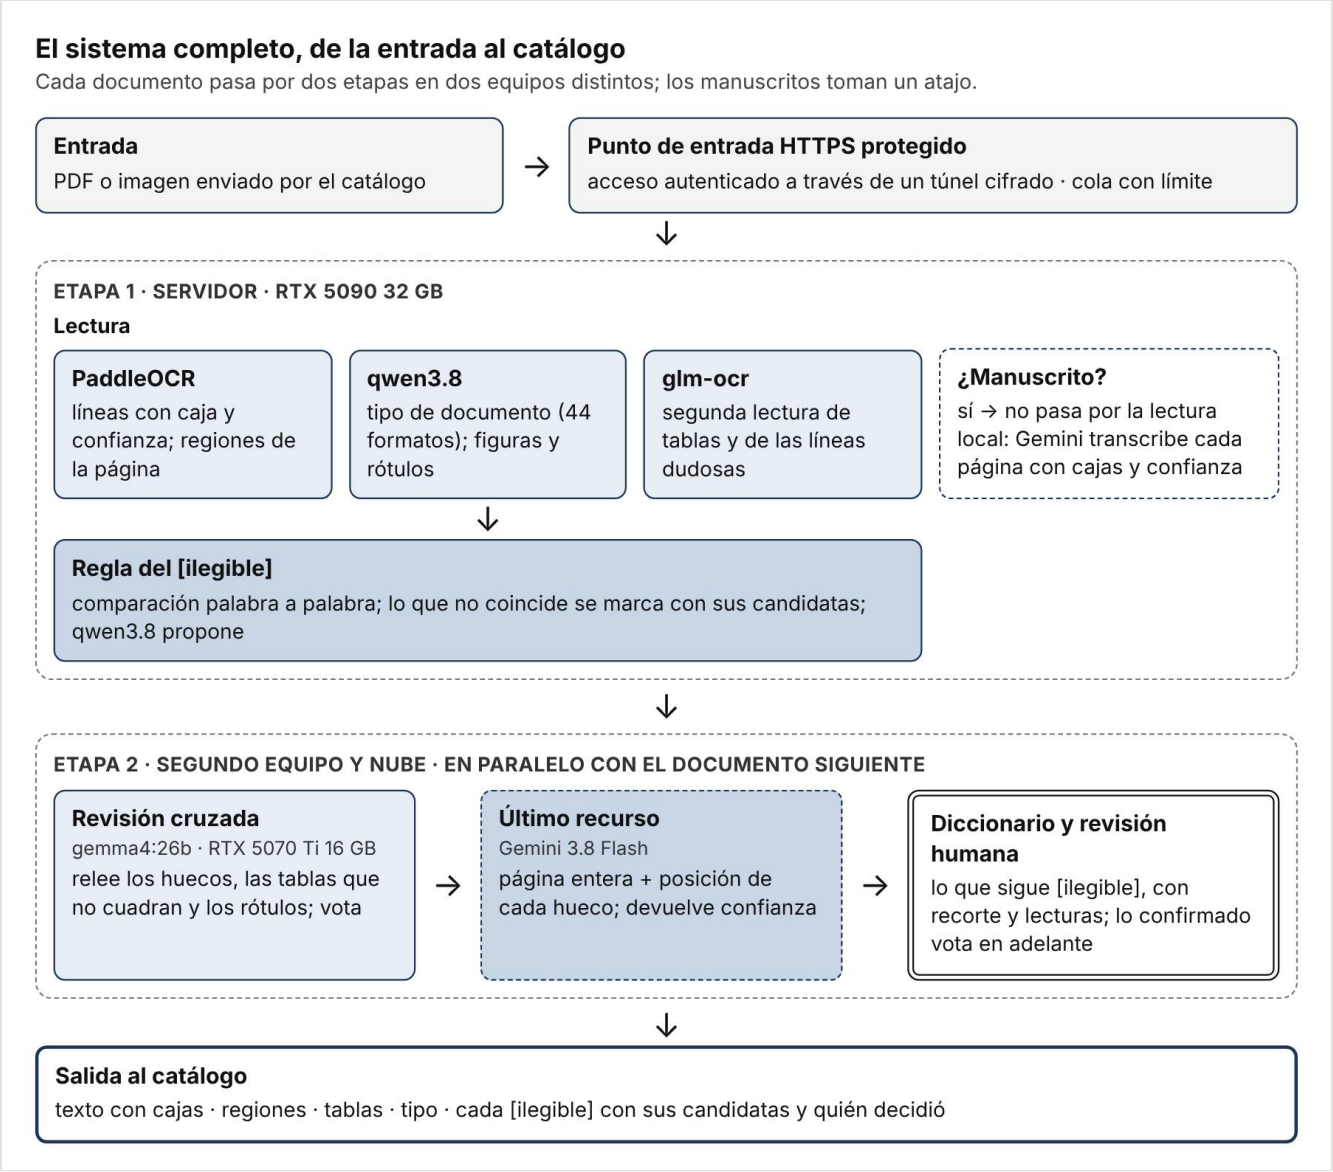


Figura 1. La etapa 1 usa solo la GPU del servidor; la etapa 2 usa la del segundo equipo y la API de Gemini, así que pueden ir en paralelo sin estorbarse. Trazo discontinuo: pasos opcionales o externos; doble trazo: intervención humana.

Tres ideas recorren todo el diseño:

- **Lectores independientes y de familias distintas.** PaddleOCR (Baidu), glm-ocr (Zhipu), qwen3.8 (Alibaba), gemma4 (Google, en local) y Gemini (Google, en la nube) se equivocan de formas diferentes. Cuando dos coinciden, la lectura es mucho más fiable que la de cualquiera de ellos por separado.
- **Mejor un hueco que un error.** Ante la duda, el sistema marca y explica: cada `[ilegible]` lleva las lecturas de todos los motores y la decisión que se tomó.
- **Comprobar con lo que el documento dice de sí mismo.** En las tablas, las filas «Suma» y «Total» permiten verificar las cifras. Una corrección solo se acepta si, con ella, la suma cuadra.

2.1 Hardware y software

Tabla 1. Equipos y motores.

Componente	Detalle	Papel
Servidor	Linux, NVIDIA RTX 5090 (32 GB), Ollama	Etapa 1 y orquestador
Segundo equipo	Windows, NVIDIA RTX 5070 Ti (16 GB), Ollama	Revisión cruzada (etapa 2)
PaddleOCR	PP-OCRv6 medium (detección y reconocimiento), PP-DocLayout_plus-L, TableRecognitionPipelineV2	Líneas con caja y confianza, regiones, tablas
glm-ocr	0,9 B parámetros	Segunda lectura de líneas y tablas
qwen3.8	27 B parámetros, unos 96 tokens/s	Clasificación, figuras, primera resolución
gemma4:26b	Mezcla de expertos; unos 82 tokens/s una vez cargado	Revisión independiente
Gemini 3.8 Flash	API de Google, razonamiento bajo, 6 peticiones en paralelo	Último recurso y manuscritos

Antes de instalar nada dejé el servidor limpio: retiré los servicios que no hacían falta y corté las conexiones salientes automáticas (actualizaciones desatendidas, informes, telemetría). El orquestador arranca con los modelos en modo sin conexión. La única salida a Internet es la API de Gemini, que se activa o desactiva desde la configuración.

2.2 Un único punto de entrada

El catálogo envía cada documento a un único punto de entrada HTTPS protegido, con acceso autenticado a través de un túnel cifrado. El orquestador no expone ningún puerto a Internet y es el único que habla con el segundo equipo, por la red interna. Así el catálogo no sabe, ni necesita saber, cuántos equipos hay detrás: si mañana añado un tercero, no cambia nada para él.

3. El proceso, fase a fase

3.1 Lectura y análisis de página

Cada página de un PDF se renderiza a 200 ppp, salvo las de gran formato (láminas, planos), que se limitan a 5.000 px de lado. PaddleOCR devuelve cada línea con su texto, su confianza y su caja, y PP-DocLayout clasifica las regiones de la página. Elegí PaddleOCR como lectura base por tres motivos: da cajas de línea precisas (que los modelos de visión generativos no garantizan), es rápido (de 0,1 a 0,5 s por página) y su confianza por línea es una señal útil para decidir qué merece una segunda lectura.

Al principio, la lectura de tablas de Paddle usaba un modelo de reconocimiento más antiguo (PP-OCRv4), que perdía las tildes, y tardaba 52 s en cargarse la primera vez. Lo resolví usando los mismos modelos v6 en todas las fases y cargándolos al arrancar el servicio.

3.2 Clasificación del documento

qwen3.8 clasifica el documento completo, no solo la portada. Ve tres páginas de muestra (la portada, la de más texto y la de figura más grande) junto con el texto OCR y el recuento de re-

giones de todo el documento. Al principio clasificaba solo por la portada, y un reglamento con láminas salía como «lámina».

Los 44 tipos describen el formato, no el tema, y se ajustan a los del catálogo. Además del tipo principal, el clasificador da la lista de tipos que contiene el documento: un Diario Oficial que publica una real orden con una lámina es «diario oficial» y contiene «real orden» y «lámina». Cada tipo va con una definición corta, porque algunos lindan entre sí (despacho y patente, informe y estudio, boletín interno y Gaceta). La clasificación marca también si el documento es mayoritariamente manuscrito, algo independiente del tipo: una hoja de servicios puede estar impresa o escrita a mano.

3.3 La regla del `[ilegible]`

Es la pieza central (Figura 2). Una línea que PaddleOCR lee con confianza baja (menos de 0,85) se contrasta con glm-ocr y se compara palabra a palabra. No cuentan como diferencia las tildes, los espacios, las mayúsculas, la puntuación ni la forma de los ordinales (`3.a`, `3.ª`, `3.º`, `2."`). Cualquier letra o cifra distinta convierte ese tramo en `[ilegible]`, y se guardan las dos lecturas. Por ejemplo, «Reqimiento» frente a «Regimiento», o «14» frente a «11».

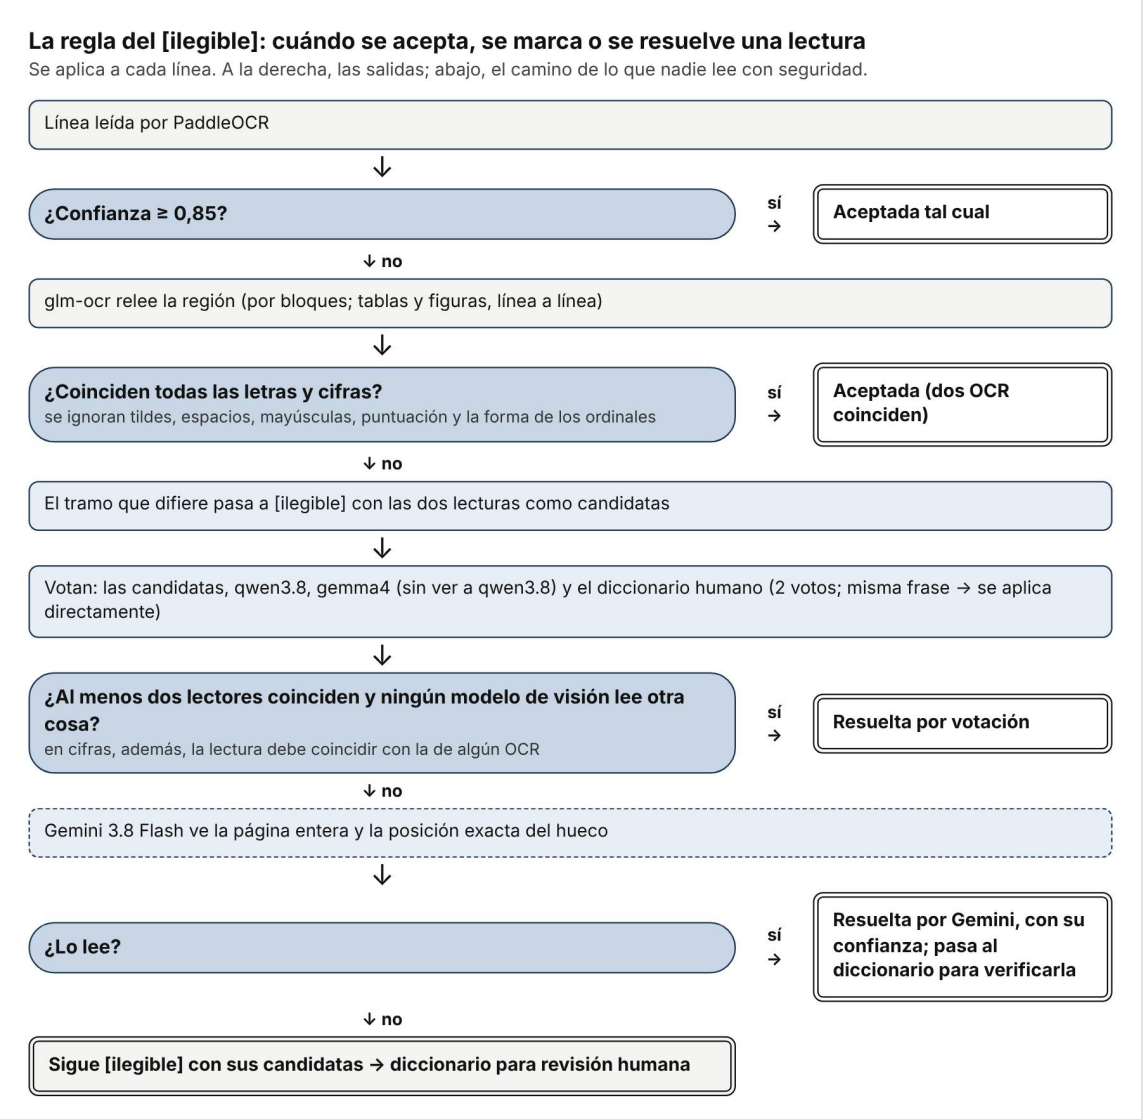


Figura 2. Decisión para cada línea. Las salidas con doble trazo son las que llegan al catálogo; Gemini (trazo discontinuo) se puede desactivar, y entonces lo no resuelto va directamente al diccionario.

Después, qwen3.8 mira el recorte de la línea, con las lecturas candidatas, y propone la palabra solo si la lee con seguridad. Dos reglas limitan lo que puede hacer:

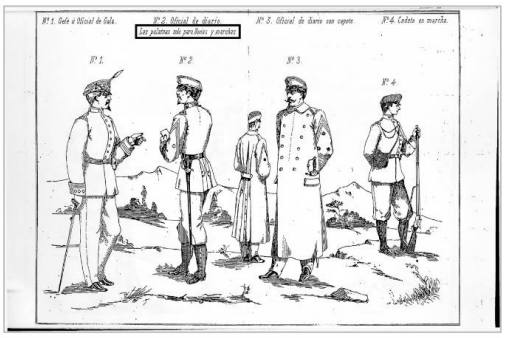
- **No toca lo que ya era seguro.** Su respuesta se rechaza si cambia las partes de la línea en las que los dos OCR coincidían.
- **En cifras no hay terceras lecturas.** Un año, una fecha o un importe tienen que coincidir con lo que leyó algún OCR. Esta regla nació de un caso real: en la portada de la cartilla de 1867, Paddle leía «157.1.» y glm-ocr «1871.», y en una versión intermedia qwen3.8 propuso «1571». Hoy el año queda marcado, con sus dos candidatas.

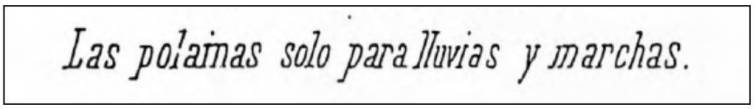
La lectura de qwen3.8 no se acepta sola. Cada hueco se decide por votación entre los lectores: los dos OCR, qwen3.8, gemma4 (sección 3.5) y el diccionario humano (sección 3.8). Se acepta la lectura que respaldan al menos dos lectores, siempre que ningún modelo de visión dé otra distinta. Cada `[ilegible]` del resultado lleva sus candidatas, la lectura de cada modelo, la confianza de Gemini si intervino y la decisión tomada, de modo que el catálogo puede explicar cada palabra: quién la leyó y por qué se aceptó.

La Figura 3 sigue un hueco real de principio a fin. En la versión 1.4, glm-ocr y qwen3.8 cometieron el mismo error («paralluvas»), y fue gemma4 quien lo frenó: el hueco quedó marcado con sus candidatas en lugar de entrar en el catálogo con una palabra que no existe.

Un hueco real, antes y después

Cartilla de uniformidad de Infantería (1867-1874), lámina de la p. 67: «Las polainas solo para lluvias y marchas.»





Lector	Lectura
PaddleOCR (confianza 0,83)	`Las polanas solo parauvias ymarchas.`
glm-ocr	`Las polainas solo paralluvas y marchas.`
Comparación	`Las [ilegible]¹ solo [ilegible]²` ¹ polanas / polainas ² parauvias ymarchas. / paralluvas y marchas.
Hueco ¹	qwen3.8 y gemma4 leen «polainas» → resuelto
Hueco ² · versión 1.4	qwen3.8: «paralluvas y marchas.» · gemma4: «para lluvias y marchas.» → discrepan → sigue [ilegible] con sus candidatas
Hueco ² · versión 1.7	qwen3.8 y gemma4 leen «para lluvias y marchas.» → resuelto

Resultado con la versión 1.4

`Las polainas solo [ilegible]`

candidatas: parauvias ymarchas. · paralluvas y marchas.

Resultado con la versión 1.7

`Las polainas solo para lluvias y marchas.`

> glm-ocr y qwen3.8 cometieron el mismo error en la 1.4; sin un lector de otra familia, «paralluvas» se habría aceptado. En la 1.7, qwen3.8 acierta, gemma4 coincide y no hace falta Gemini.

Figura 3. Resultados reales del sistema en la noche de producción (versión 1.4) y al reprocesar la página con la versión actual (1.7). Impreso de 1867, sin datos personales.

Las líneas dudosas se contrastan por bloques: glm-ocr lee de una vez la región entera (hasta 30 líneas) y su lectura se alinea palabra a palabra con las líneas de Paddle. Las líneas de tablas, figuras y sellos se contrastan una a una, porque glm-ocr, leyendo una tabla de cifras como texto corrido, entraba en bucle (sección 7).

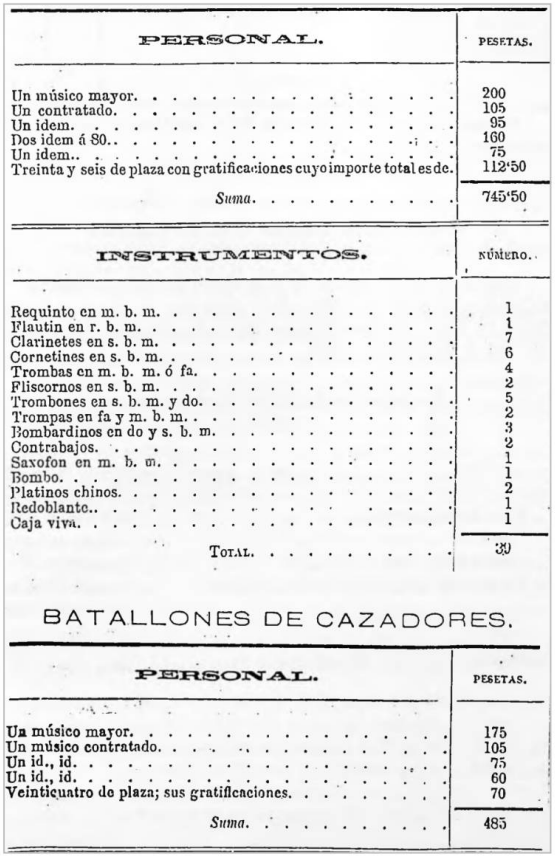
3.4 Tablas: doble lectura y sumas

Cada tabla se lee con glm-ocr, que es el que mejor reconstruye la estructura, y se convierte en HTML. PaddleOCR la relee solo si glm-ocr falla, si su texto se aleja del OCR o si sus sumas no cuadran. A veces glm-ocr se deja la parte de abajo de una región (dos tablas seguidas, por ejemplo): entonces se detectan las líneas del OCR que no aparecen en ninguna celda, se recorta lo que falta y se vuelve a leer.

Después se comprueban las filas «Suma», «Total» y similares contra la suma de su sección. Se entienden `112'50`, `745,50`, `1.250,75` y el calderón de millar (`2U500`). Una celda con «ídem» o con comillas cuenta como el valor de la fila de arriba. Si una suma no cuadra, las celdas de esa columna se releen en la etapa 2, primero con gemma4 y, si sigue sin cuadrar, con Gemini. La corrección solo se acepta si con ella la suma pasa a cuadrar (Figura 4).

Comprobar las sumas: corregir lo que se lee mal y no «arreglar» el original

Cartilla de uniformidad de Infantería (1867-1874), p. 55. Tres comprobaciones de sumas en la misma página.



PERSONAL.	PESETAS.
Un músico mayor.	200
Un contratado.	105
Un idem.	95
Dos idem á 80.	160
Un idem..	75
Treinta y seis de plaza con gratificaciones cuyo importe total es de.	112'50
Suma.	745'50

INSTRUMENTOS.	NÚMERO.
Requinto en m. b. m.	1
Flautin en r. b. m.	1
Clarinetes en s. b. m.	7
Cornetines en s. b. m.	6
Trombas en m. b. m. ó fa.	4
Fliscornos en s. b. m.	2
Trombones en s. b. m. y do.	5
Trompas en fa y m. b. m.	2
Bombardinos en do y s. b. m.	3
Contrabajos.	2
Saxofon en m. b. m.	1
Bombo.	1
Platinos chinos.	2
Redoblante..	1
Caja viva.	1
TOTAL.	39

BATALLONES DE CAZADORES.

PERSONAL.	PESETAS.
Un músico mayor.	175
Un músico contratado.	105
Un id., id.	75
Un id., id.	60
Veinticuatro de plaza; sus gratificaciones.	70
Suma.	485

Fila	Leído	Comprobación	Resultado
Suma (personal)	745'50	las filas suman 747,50	**error del propio impreso**: queda marcado; gemma4 y Gemini lo revisan y no lo cambian
Total (instrumentos)	30	las filas suman 39	gemma4 relee la celda desvaída: **39**; ahora cuadra
Suma (Cazadores)	485	cuadra	segunda tabla de la página, recuperada entera

> Un descuadre no siempre es un error de lectura: el impreso dice 745'50 donde las filas suman 747,50. El sistema lo señala para revisión humana.

Figura 4. Las tres comprobaciones de sumas de la página 55 y lo que salió de cada una.

Una tabla con más de tres descuadres no se relee celda a celda. Suele tratarse de una estructura mal leída, o de unos «totales» que no son sumas, como los estados de fuerza orgánica de un escalafón. Queda marcada para revisión humana.

3.5 Revisión cruzada en el segundo equipo

El segundo equipo ejecuta gemma4:26b, un modelo de otra familia que qwen3.8. Recibe los mismos recortes y las mismas lecturas de OCR, pero *no* la propuesta de qwen3.8, para que su voto sea independiente. Revisa tres cosas: los huecos `[ilegible]`, las tablas cuyas sumas no cuadran y los rótulos de figuras que el OCR no respaldó. La regla de votación es la de la sección 3.3; si gemma4 y qwen3.8 leen cosas distintas, el hueco queda marcado aunque uno de los dos coincida con un OCR.

Lo elegí porque es el mejor modelo de visión disponible en Ollama que funciona en una GPU de 16 GB a una velocidad útil: unos 0,7 s por línea revisada. En la noche de producción, gemma4 confirmó 1.961 lecturas, resolvió por su cuenta 1.314 y frenó 973 que qwen3.8 había dado por buenas y que ningún otro lector respaldaba. Si el segundo equipo está apagado, el documento se procesa igual, sin esta revisión, y el resultado lo indica.

3.6 Gemini como último recurso

Lo que sigue sin resolver después de cuatro lectores se manda a Gemini 3.8 Flash, en una sola llamada por página. Cada llamada lleva la página entera y, para cada hueco:

- la caja de su línea, en el formato de Gemini: `[ymin, xmin, ymax, xmax]` normalizado a 0-1000;
- la posición aproximada de la palabra dentro de la línea;
- la línea con el hueco marcado y las líneas vecinas, como contexto;
- lo que leyó cada motor.

Gemini contesta todos los huecos de la página a la vez y declara su confianza en cada uno. Como llega cuando nadie más ha sabido resolverlo, su lectura se acepta. La confianza se guarda en el resultado y en el diccionario, para que una persona revise primero las de menor confianza. Las páginas se envían de seis en seis. Con el razonamiento al nivel por defecto, cada página tardaba entre 5 y 90 s; con el nivel bajo, unos 5 s, lo que suma de 4 a 8 s por documento de 12 páginas.

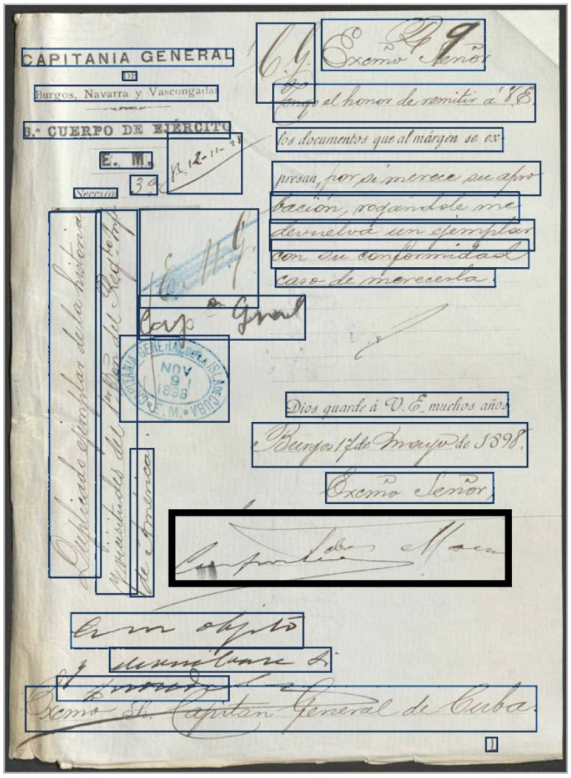
Gemini es la única conexión del servidor con el exterior, y la decisión fue explícita: las páginas que llegan a esta fase salen a Google. Se puede desactivar por documento o para todo el servicio.

3.7 Manuscritos

Un documento mayoritariamente manuscrito no se puede leer bien con los motores locales. Antes de separarlos, un expediente de 23 páginas dejó 2.184 `[ilegible]` después de pasar por todos los lectores. Ahora, cuando el clasificador marca un documento como manuscrito, el servidor solo hace el análisis de página y la clasificación, y Gemini transcribe cada página entera. Devuelve las líneas en orden de lectura, cada una con su caja, el texto literal (con `[ilegible]` donde no se lee) y su confianza (Figura 5).

Manuscritos: transcripción directa con Gemini

Expediente de 1898 (Capitanía General de Burgos, Navarra y Vascongadas), p. 1. Cajas devueltas por Gemini: trazo continuo, confianza ≥ 0,8; trazo grueso, < 0,8.



Texto	Conf.
CAPITANIA GENERAL / DE / Burgos, Navarra y Vascongadas	0,98-0,99
6.º CUERPO DE EJÉRCITO · E. M. · Sección 3.ª	0,97-0,99
Excmo. Señor	0,96
Tengo el honor de remitir á V.E.	0,98
los documentos que al márgen se ex-	0,98
presan, por si merece su apro-	0,97
Duplicado ejemplar de la historia (margen)	0,95
y vicisitudes del 1.er Bon del Reg.to Inf.ª	0,95
CAPITANIA GENERAL DE LA ISLA DE CUBA / NOV 9 1898 / E. M. (sello)	0,92
Burgos 17 de Mayo de 1898.	0,98
Castor de Moxin (firma)	**0,75**
Excmo. Sr. Capitan General de Cuba.	0,97

> La única línea por debajo de 0,8 es la firma. En 6 páginas: 180 líneas en 44 s, confianza media 0,96. Antes, un expediente manuscrito de 23 páginas dejaba 2.184 [ilegible].

Figura 5. Expediente de 1898, página 1, con las cajas de línea que devuelve Gemini. Las personas citadas en el documento son del siglo XIX.

3.8 Diccionario y revisión humana

Todo `[ilegible]` que queda pasa a un diccionario para revisión humana. Cada entrada lleva:

- la palabra (`[ilegible]` hasta que alguien la lee);
- la frase en la que aparece;
- las lecturas de cada motor;
- un recorte de la línea, y el documento y la página de origen.

Una página web de revisión enseña las pendientes con su recorte. Basta con escribir la palabra o pulsar una de las lecturas propuestas. Las resoluciones de Gemini entran también, ordenadas de menor a mayor confianza, para que una persona las confirme o las corrija.

Lo que confirma una persona pasa a ser un lector más. Si la frase es la misma (un documento que se vuelve a procesar), su lectura se aplica directamente. Si es la misma confusión de OCR en otra frase, vale dos votos, salvo que un modelo de visión lea otra cosa. Si dos personas validaron palabras distintas para la misma confusión, el diccionario no se usa en ese caso. Después de la primera noche de producción, el diccionario tenía unas 3.000 entradas pendientes.

3.9 Signos y convenciones de época

Estos documentos usan signos que no son errores ni texto ilegible, y que, sin explicárselos a los correctores, generaban marcas falsas (Tabla 2). Los tres correctores (qwen3.8, gemma4 y Gemini) reciben la guía en cada consulta. La misma guía alimenta la comparación entre lectu-

ras y la aritmética de las tablas. En siete páginas de la cartilla, las marcas bajaron de unas 15 a 9; las que quedan son errores reales, como «FigunA» frente a «FIGURA».

Tabla 2. Convenciones que el sistema reconoce.

Qué	Formas	Significado y tratamiento
Repetición	Ídem, ídem, id., íd.; comillas o signos solos: " ″ » « >> << 〃	«Igual que arriba». Se transcribe el signo; en las tablas cuenta como el valor de la fila de arriba y queda señalado en el resultado.
Ordinales	1.º, 2.ª, N.º (el OCR los lee como 1." o 2.a)	«2."» y «2.º» son la misma lectura.
Abreviaturas	D., D.ª, S.M., V.E., Excmo., R.O., R.O.C., D.O., C.L., dho., qe., Tte., Cap., Rgto., Inf.ª, 7bre… Xbre	Se transcriben sin desarrollar.
Monedas y medidas	rs. vn., mrs., escs., ptas., cts., @ (arroba), lib., onz., fan., vs., pulg.	Se ignoran al leer la cifra.
Cifras	112'50; 2U500	112,50; 2.500 (calderón de millar).
Celda sin valor	— · .... · …	«Nada» o «no corresponde»; no corta la sección de la tabla.

4. Operación: cola, etapas y registros

El sistema tiene que aguantar meses de carga continua sin perder trabajos ni saturarse. Estas son las decisiones de operación:

- **Cola con límite.** Admite hasta 200 trabajos en espera; por encima, pide al catálogo que vuelva a intentarlo más tarde. Si queda poco disco libre, deja de aceptar trabajos. Cada trabajo aceptado devuelve su posición y una espera estimada a partir de lo que tardan los trabajos reales.
- **Dos etapas en paralelo.** El servidor procesa un documento mientras la etapa 2 termina el anterior. Entre las dos hay como mucho un documento esperando, así que en memoria nunca hay más de tres documentos.
- **Reinicios sin pérdidas.** Al arrancar, los trabajos en cola, y el que estaba en marcha, se retoman solos. Lo he comprobado varias veces con trabajos reales.
- **Memoria de la GPU.** PaddleOCR devuelve su memoria después de cada página. Si aun así se queda sin memoria, se descargan los modelos de Ollama y se reintenta; si vuelve a fallar, se reintenta con la página reducida.
- **Registros.** Cada trabajo deja una línea con tiempos por fase, páginas, tipo, `[ilegible]` puestos y resueltos, tablas y resultados de cada lector. No se guarda el texto. Cada excepción se registra con su traza y una copia del documento que la produjo, para reproducirla. Cada hora, un informe resume la hora anterior.
- **Retención.** El documento subido se borra al terminar de procesarlo, y el resultado a las 4 horas o al descargarlo. Las copias de documentos con excepciones se guardan 30 días; los registros, 90 días. El segundo equipo no guarda nada.

5. Cómo lo he probado

Todavía no tengo un conjunto de páginas transcritas a mano con el que medir la precisión carácter a carácter. Lo medido hasta ahora son señales internas: cuántas líneas leen los dos

OCR igual, cuántos huecos se marcan y se resuelven, cuántas sumas cuadran y cuánto tarda cada fase. Además, he revisado a mano los casos difíciles. Es la principal limitación de este informe (sección 8).

Tabla 3. Conjuntos de prueba.

Prueba	Contenido	Para qué
Cartilla de 1867	Cartilla de uniformidad de Infantería, 72 páginas; tablas en pp. 55-56, láminas en pp. 63-67	Referencia fija entre versiones; revisión a mano de cada marca
106 muestras	Dos páginas de cada documento, de 11 tipos del catálogo	Velocidad y robustez (v1.1)
Lote de 8	Escalafones, Estado Militar de 1826, Colección Legislativa de 1929, libros, cartillas; 12 páginas cada uno, enviados a la vez	Comparar versiones con la cola llena
Noche de producción	149 documentos del archivo, 4.093 páginas en unas 8 horas	Comportamiento con carga real
Manuscrito	Expediente de la Capitanía General de Burgos de 1898	Ruta de manuscritos

6. Resultados

6.1 Historia de versiones

El sistema llegó a su forma actual en siete versiones. Cada una respondió a un problema medido en la anterior (Figura 6).

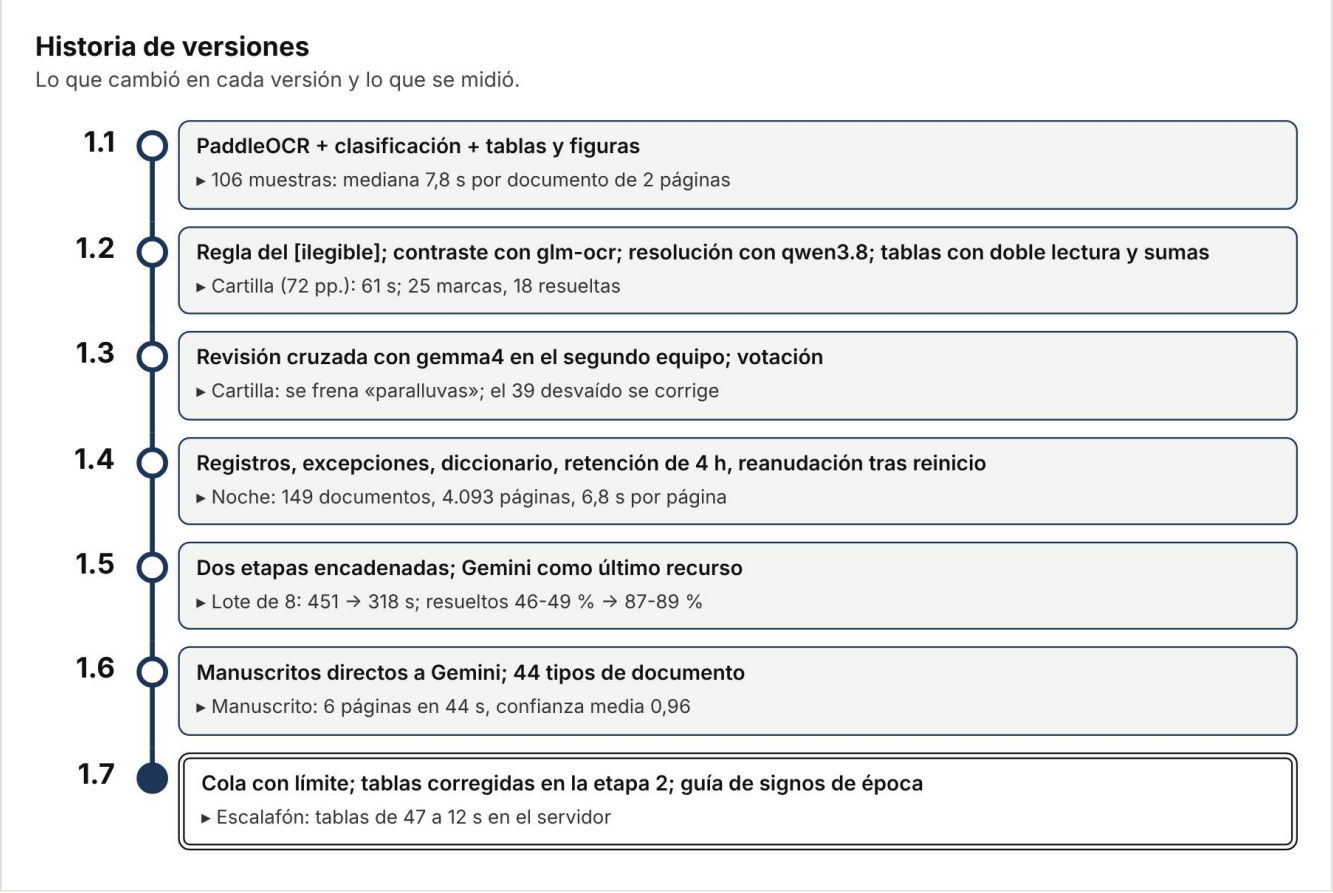


Figura 6. Evolución del sistema. La versión 1.7 es la actual.

6.2 La noche de producción

Durante una noche de producción de unas 8 horas, el catálogo envió 149 documentos sin pausa, con la versión 1.4 (una sola etapa, la revisión con tope de 80 elementos por documento y sin Gemini).

4.093	6,8 s	511.017	17
páginas en unas 8 horas	por página (unas 500 páginas/hora)	líneas leídas; el 96 % sin dudas	documentos fallidos (11 %), todos por memoria de GPU

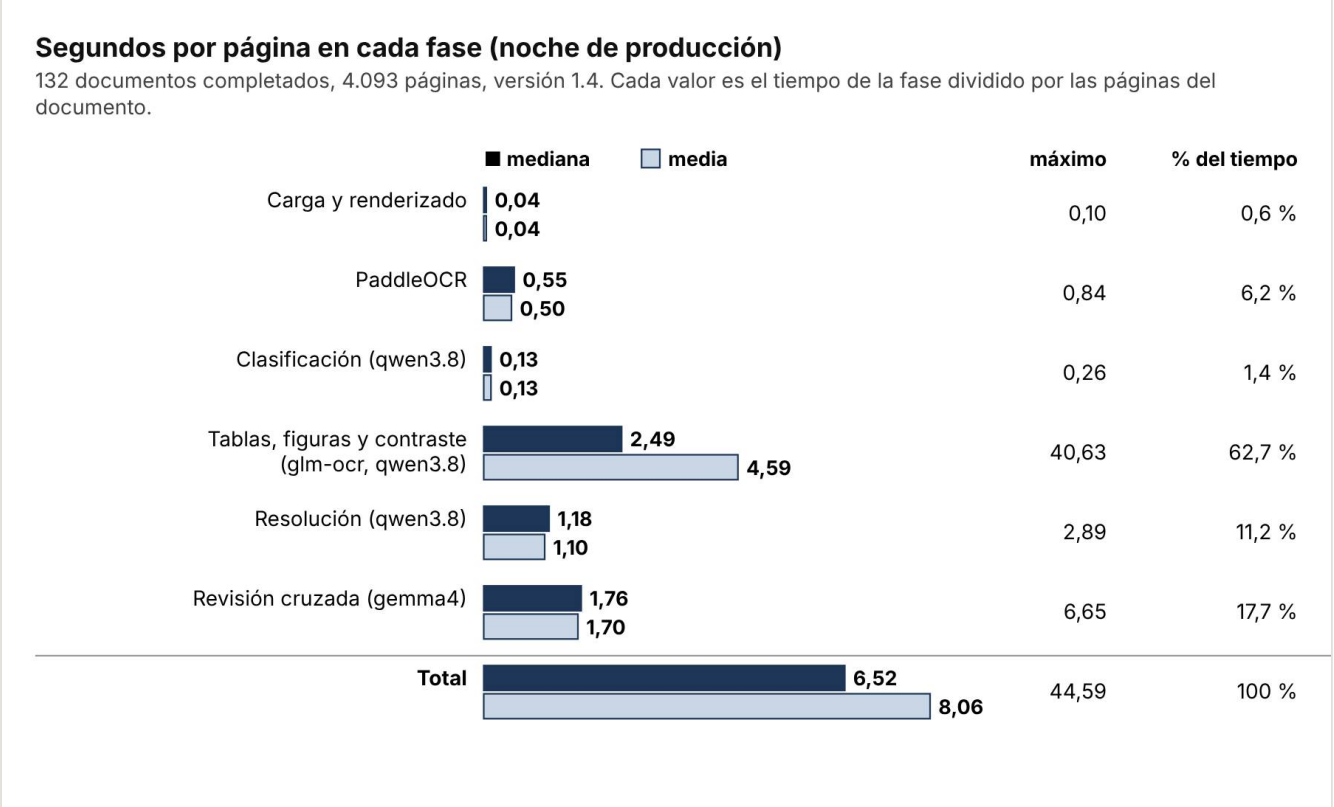


Figura 7. Tiempo por página de cada fase. El bloque de tablas, figuras y contraste se lleva el 63 % del tiempo y es el que más varía de un documento a otro (máximo de 40,6 s por página). El desglose fino de la versión 1.7 mostró que, dentro de ese bloque, lo caro no era el contraste de líneas (de 0,3 a 5 s por documento de 12 páginas), sino releer celdas cuyas sumas no cuadraban, las regiones tomadas por manuscritas y las figuras.

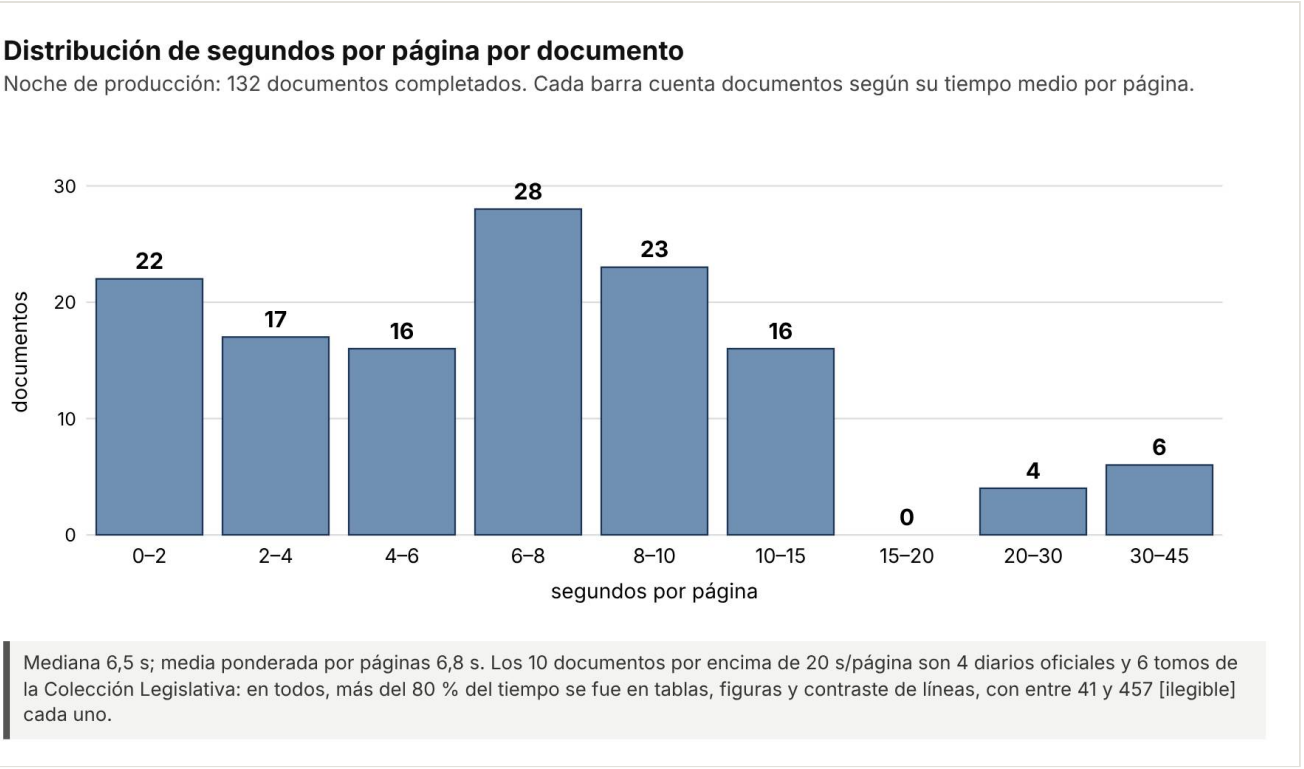


Figura 8. Los registros guardan el tiempo por documento, no por página; por eso el histograma usa la media de cada documento.

De los 19.757 `[ilegible]` marcados, se resolvieron 3.276 (17 %). La cifra es baja por dos motivos. El primero es que están muy concentrados: diez documentos acumulan el 54 % de los pendientes, y son escaneos muy deficientes o manuscritos, con hasta 92 marcas por página. El segundo es que la revisión tenía tope: en los 80 documentos que gemma4 pudo revisar enteros se resolvió el 42 %, y en los 52 que tocaron el tope, el 11 %. Los dos problemas están resueltos: los manuscritos van ahora a Gemini (sección 3.7) y la revisión no tiene tope. En las tablas, la comprobación de sumas corrigió 505 celdas, y 225 de las 1.757 tablas (13 %) quedaron con algún descuadre para revisión.

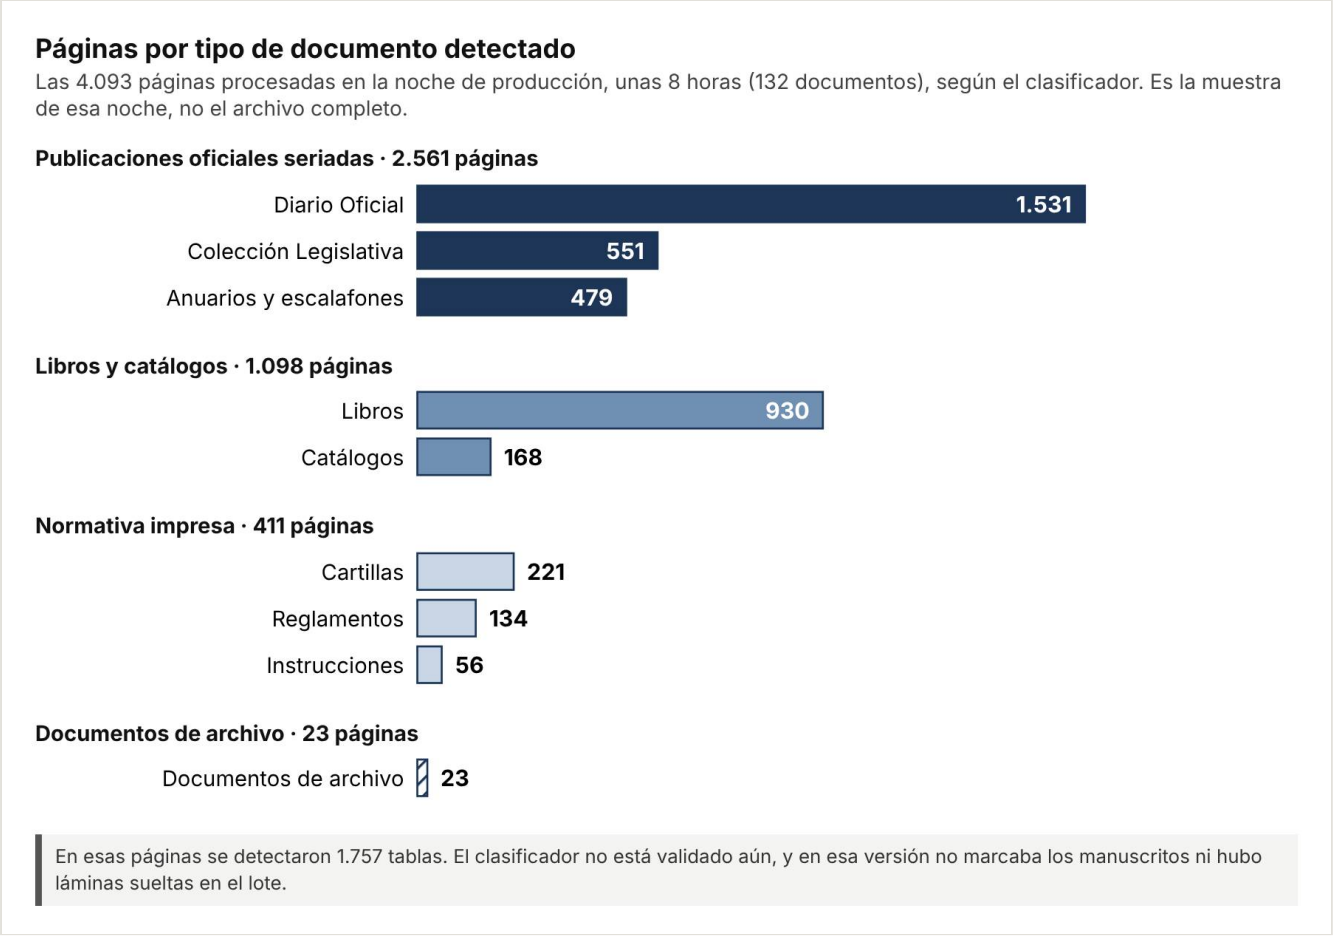


Figura 9. Reparto de las páginas de esa noche por tipo detectado. Sirve para leer las figuras 7 y 8, no como inventario del archivo.

6.3 Encadenar etapas y añadir Gemini

Con la versión 1.5, el mismo lote de ocho documentos de 12 páginas se procesó con las etapas encadenadas y, después, con Gemini como último recurso (Figuras 10 y 11).

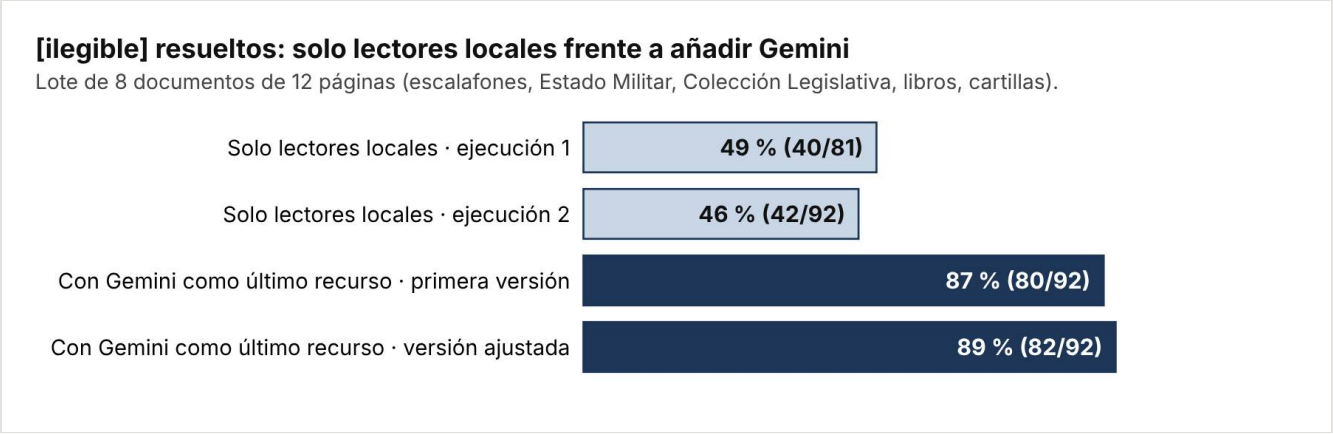


Figura 10. Proporción de `[ilegible]` resueltos en el lote. Entre paréntesis, resueltos sobre marcados en cada ejecución.



Figura 11. Tiempo de reloj del lote completo. En la primera versión con Gemini, que razonaba por defecto y procesaba las páginas una a una (de 5 a 90 s cada una), el lote tardó 780 s; con razonamiento bajo y 6 páginas en paralelo, Gemini añade de 4 a 8 s por documento.

En el lote, el servidor (etapa 1) suma unos 280 s y la etapa 2 unos 200. Al encadenarlas, el tiempo total se acerca al de la etapa más lenta, no a la suma. Hoy el cuello de botella es el servidor, y dentro de él, las tablas.

6.4 Tablas y manuscritos

Tabla 4. Cambios medidos en un escalafón de 12 páginas y en el manuscrito.

Caso	Antes	Después	Qué cambió
Tablas del escalafón, en el servidor	47 s	12 s	La relectura de celdas pasa a la etapa 2. La tabla de fuerza orgánica (32 «descuadres» que no son sumas) se marca para revisión humana sin intentarla.
Etapa 1 del escalafón	≈ 70 s	≈ 40 s	Lo anterior, más PaddleOCR solo cuando glm-ocr falla (2 s menos).
Gemini con las tablas del escalafón	> 10 min	4 s	Antes, una llamada por cada suma que no cuadraba. Ahora como mucho 3 por tabla, y en paralelo.
Expediente manuscrito	2.184 marcas en 23 pp.	6 pp. en 44 s	Directo a Gemini; confianza media de 0,96.
Zonas «manuscritas» en impresos	30-52 s	0 s	Ya no se releen (una firma bastaba para releer todo el texto).

7. Qué funcionó y qué no

La Figura 12 resume las decisiones con la medida que las justificó. Las tres lecciones principales: marcar en lugar de adivinar evita errores que nadie volvería a mirar; un lector de otra familia detecta los errores que comparten dos motores; y las sumas de las tablas son la única prueba objetiva que no depende de ningún modelo. Casi todo lo que no funcionó tenía la misma raíz: pedir a un modelo que leyera sin una referencia contra la que comprobarlo, o pagar un coste fijo (memoria, relecturas, razonamiento) en documentos que no lo necesitaban.

Qué funcionó y qué no, con la medida que decidió

Cada decisión se tomó a partir de una medida en documentos reales.

Funcionó

	medida
✓ **Marcar en lugar de adivinar**	evitó el año inventado «1571» de una portada
✓ **Lectores de familias distintas**	gemma4 frenó 973 lecturas que solo respaldaba qwen3.8
✓ **Las sumas como prueba objetiva**	505 celdas corregidas en una noche; el 745'50 queda como error del impreso
✓ **Dos etapas en dos GPU**	451 → 318 s en el mismo lote
✓ **Gemini solo al final**	46-49 % → 87-89 % resueltos; 4-8 s por documento
✓ **Manuscritos directos a Gemini**	2.184 marcas en 23 pp. → 6 pp. en 44 s
✓ **Registros con copia del fichero**	la causa de 17 fallos, localizada en minutos

No funcionó → qué hicimos

	medida	decisión
× **Modelo de visión como segunda opinión libre**	bucles y lecturas plausibles pero falsas	→ glm-ocr + comparación palabra a palabra
× **Describir todas las figuras**	objetos inventados en bordes de escaneo	→ filtro de bordes; respuesta «texto» o «vacío»
× **Clasificar por la portada**	reglamentos con lámina tomados por láminas	→ 3 páginas de muestra + regiones de todo el documento
× **Comparación laxa**	«Reqimiento» pasaba por bueno	→ comparación por esqueleto
× **qwen3.8 resolviendo solo**	inventó «1571»	→ regla de las cifras + votación
× **Tope de 80 elementos de revisión**	11 % resuelto en los documentos que lo tocaban	→ sin tope
× **Memoria de GPU retenida por PaddleOCR**	17 de 149 documentos fallidos (11 %)	→ liberar tras cada página; reintentos
× **glm-ocr en el segundo equipo**	no cabe junto a gemma4 en 16 GB	→ se queda en el servidor
× **glm-ocr por bloques para ganar velocidad**	sin ganancia medible (0,3-5 s por documento)	→ se mantiene: contrasta todas las líneas dudosas
× **Bloques con líneas de tablas**	glm-ocr en bucle (14 casos)	→ tablas y figuras, línea a línea
× **Releer zonas «manuscritas» de impresos**	30-52 s por documento	→ eliminado; manuscritos completos a Gemini
× **Gemini con razonamiento por defecto**	5-90 s por página	→ razonamiento bajo, 6 páginas en paralelo: ~5 s
× **Gemini celda a celda en cualquier tabla**	más de 10 min en un escalafón	→ máximo 3 descuadres por tabla
× **Releer celdas con qwen3.8 en el servidor**	33 s por escalafón, 0 correcciones	→ pasa a la etapa 2

Figura 12. Qué funcionó y qué no. Todas las medidas son de documentos reales del archivo.

8. Limitaciones y problemas abiertos

- **Falta un conjunto de referencia.** No he medido la precisión carácter a carácter. Las cifras de este informe dicen cuánto duda el sistema y cuánto resuelve, no cuántos errores quedan sin marcar. Un error en el que coinciden dos lectores, sin que ningún modelo de visión lo contradiga, pasa sin marca.

- **La clasificación no está validada.** En las 106 muestras, el tipo detectado coincidió con el del catálogo en 33 casos. Muchas diferencias son discutibles: el catálogo usa «otro» para lo que el clasificador llama diario oficial o fotografía de pieza, y hay ficheros que no corresponden a su ficha. Aun así, falta una revisión sistemática. También quedan ambigüedades reales entre tipos, como lámina y dibujo o despacho y patente.
- **La confianza de Gemini es declarada, no calibrada.** Sirve para ordenar la revisión humana, pero no he comprobado que un 0,9 signifique un 90 % de aciertos.
- **Tablas con «totales» que no son sumas.** Se marcan para revisión en lugar de interpretarse.
- **Capacidad de revisión humana.** Tras una sola noche, el diccionario tenía unas 3.000 entradas pendientes. A la escala del archivo habrá que priorizar: por frecuencia, por confianza y por tipo de documento.
- **Dependencias.** Si el segundo equipo está apagado, no hay revisión cruzada; si la API de Gemini no responde, no hay último recurso. En los dos casos el documento se procesa igual, y el resultado indica qué faltó.
- **Coste de Gemini.** Se registra por trabajo (tokens de entrada y salida), pero aún no lo he medido a escala. Una página de la cartilla con un hueco consumió unos 2.400 tokens de entrada y 1.300 de salida; las seis páginas del manuscrito, 7.638 y 21.078.

9. Siguiente paso: las 300.000 páginas

Este informe es preliminar. Todo lo anterior se ha medido con unas 4.000 páginas; el archivo tiene más de 300.000. Con unos 6,8 s por página, como en la noche de producción, serían unas 570 horas de proceso continuo, entre tres y cuatro semanas. Encadenar las etapas debería reducirlo; revisar sin tope y añadir Gemini lo aumentan. Es un orden de magnitud que mediré sobre la marcha. El plan es empezar por un bloque de unas 10.000 páginas, representativo de los tipos del archivo, y fijar con él:

1. **Un conjunto de referencia** de unas 200 páginas transcritas o verificadas a mano y repartidas por tipos, para medir por primera vez la tasa de error real, la de errores sin marcar y la calibración de la confianza de Gemini.
2. **Velocidad y coste reales** por tipo de documento: páginas por hora, tiempo de cada etapa y tokens de Gemini por página.
3. **Volumen de revisión humana**: entradas nuevas del diccionario por cada 1.000 páginas, y cuántas resuelve el propio diccionario conforme crece.
4. **Estabilidad**: fallos y excepciones por cada 1.000 páginas.
5. **El cuello de botella**: si sigue siendo la lectura de tablas en el servidor, atacarlo antes de lanzar el resto.

Con esos datos sabré si la configuración actual basta para el archivo completo o si conviene añadir capacidad, ajustar umbrales o cambiar qué documentos van directos a Gemini. La versión definitiva de este informe se escribirá con esos resultados, y el archivo y el catálogo se irán publicando en línea a medida que se procesen.